Klasifikacija uporabom umjetnih neuronskih mreža

Darijo Brčina

Sveučilište u Zagrebu
Fakultet elektrotehnike i računarstva

Završni rad br. 6950

Zagreb, 06.07.2020

Sadržaj

Opis zadatka

Cilj:

- naučiti neuronsku mrežu da na temelju danih labeliranih podataka jasno može odrediti kojem razredu pripadaju

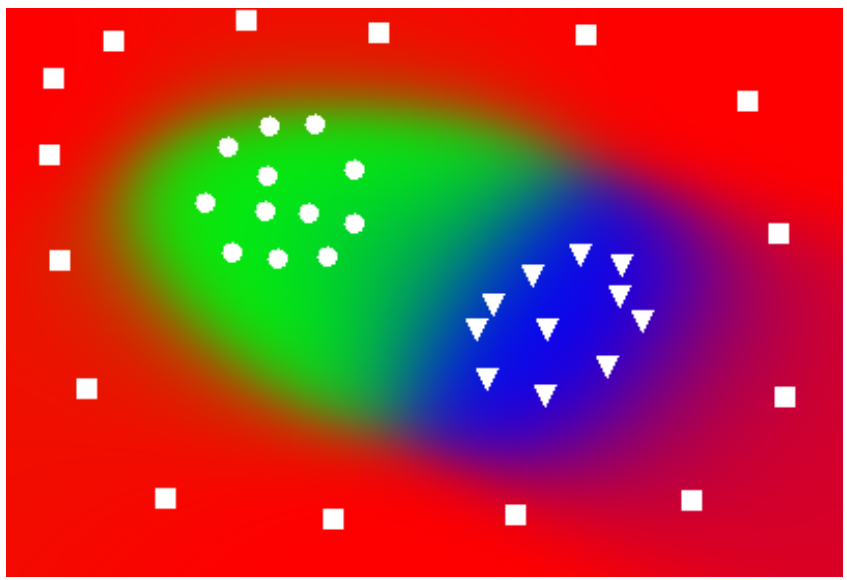

Nadzirano učenje

- Jedno od glavnih područja strojnog učenja
- Model nadziranog učenja (engl. *supervised learning*) prolazi kroz dvije faze:

Nadzirano učenje

- Jedno od glavnih područja strojnog učenja
- Model nadziranog učenja (engl. *supervised learning*) prolazi kroz dvije faze:

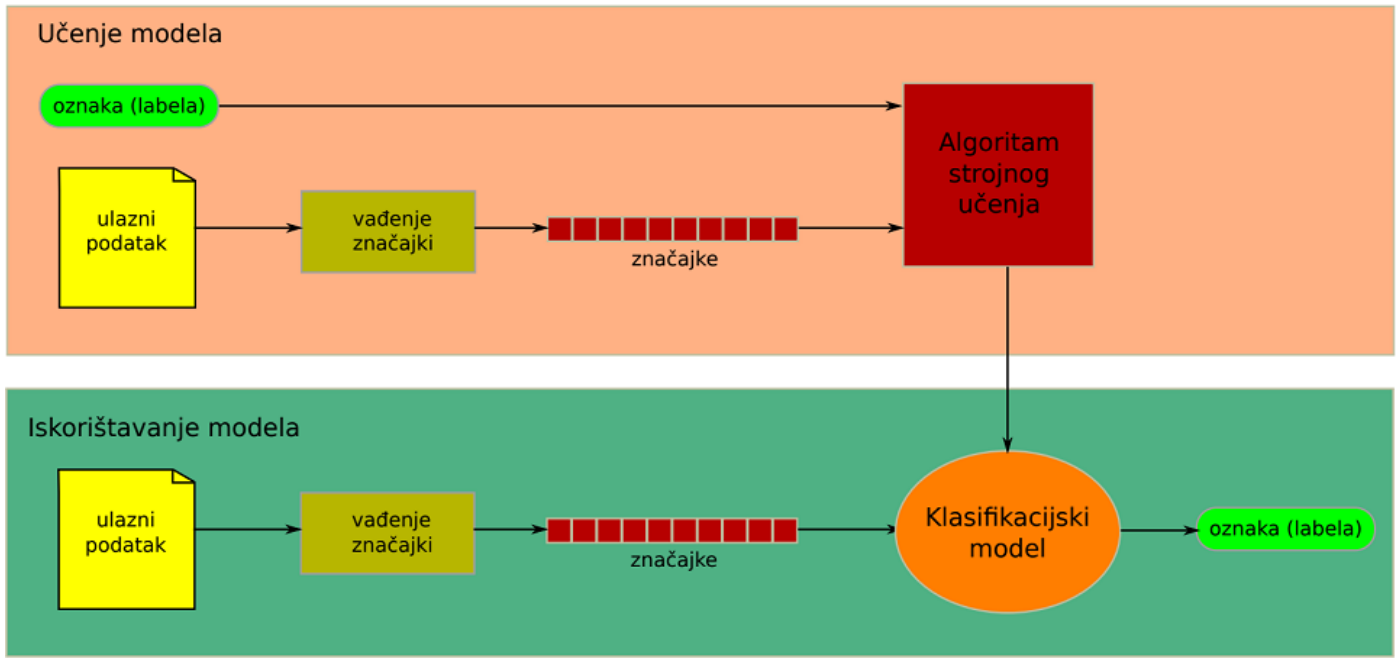

Nadzirano učenje

- Jedno od glavnih područja strojnog učenja
- Model nadziranog učenja (engl. *supervised learning*) prolazi kroz dvije faze:

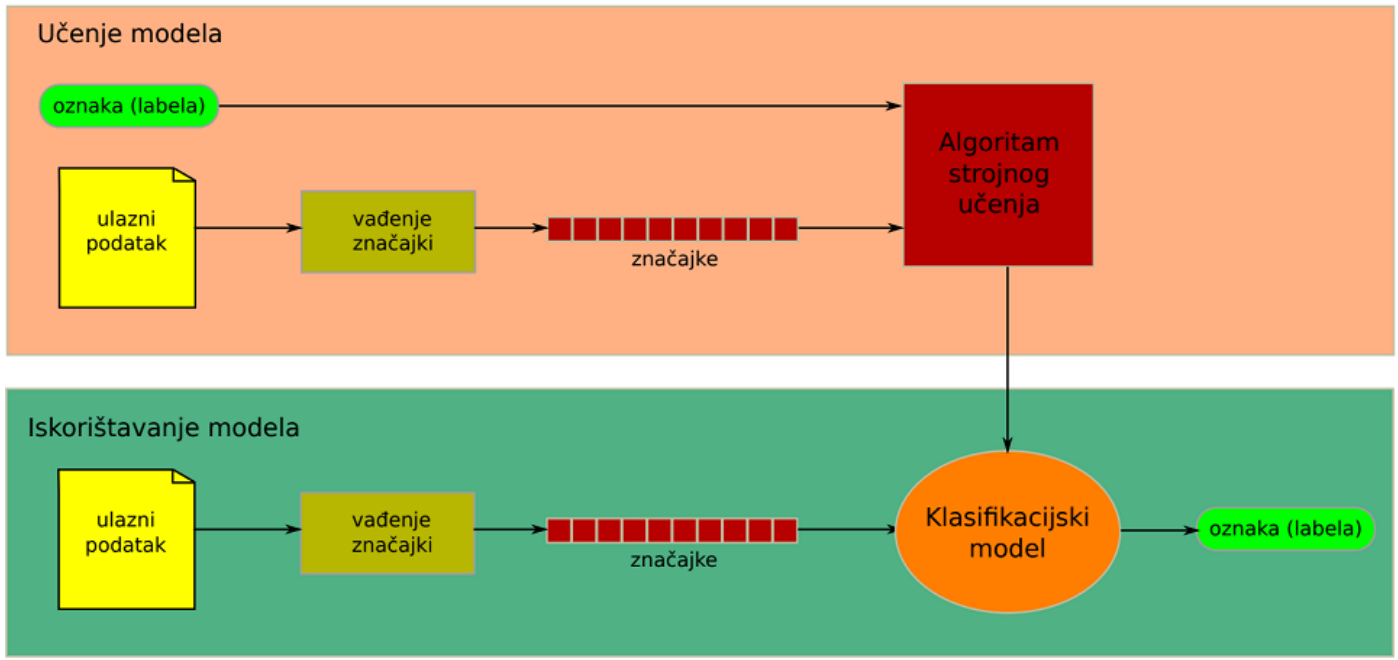

- Glavni cilj je omogućiti da model razvije svojstvo **generalizacije**
- Ispostavlja se da je to dosta zahtjevno za izvesti pa često dolazi do problema **prenaučenosti** (engl. *overfitting*)

Lijek za prenaučenost

- Prenaučenost je jedan od glavnih problema strojnog učenja koji model čini beskorisnim zbog loše generalizacije
- Jedan od načina kako spriječiti prenaučenost je korištenje metode **unakrsna provjera** (engl. *cross-validation*)
- Ideja je da se oko 30% uzoraka **skupa za učenje** (engl. *training set*) prebaci u **skup za provjeru** (engl. *validation set*) te prati pogreška nad oba skupa pomoću koje ćemo odrediti kada je učenje modela potrebno zaustaviti:

Lijek za prenaučenost

- Prenaučenost je jedan od glavnih problema strojnog učenja koji model čini beskorisnim zbog loše generalizacije
- Jedan od načina kako spriječiti prenaučenost je korištenje metode **unakrsna provjera** (engl. *cross-validation*)
- Ideja je da se oko 30% uzoraka **skupa za učenje** (engl. *training set*) prebaci u **skup za provjeru** (engl. *validation set*) te prati pogreška nad oba skupa pomoću koje ćemo odrediti kada je učenje modela potrebno zaustaviti:

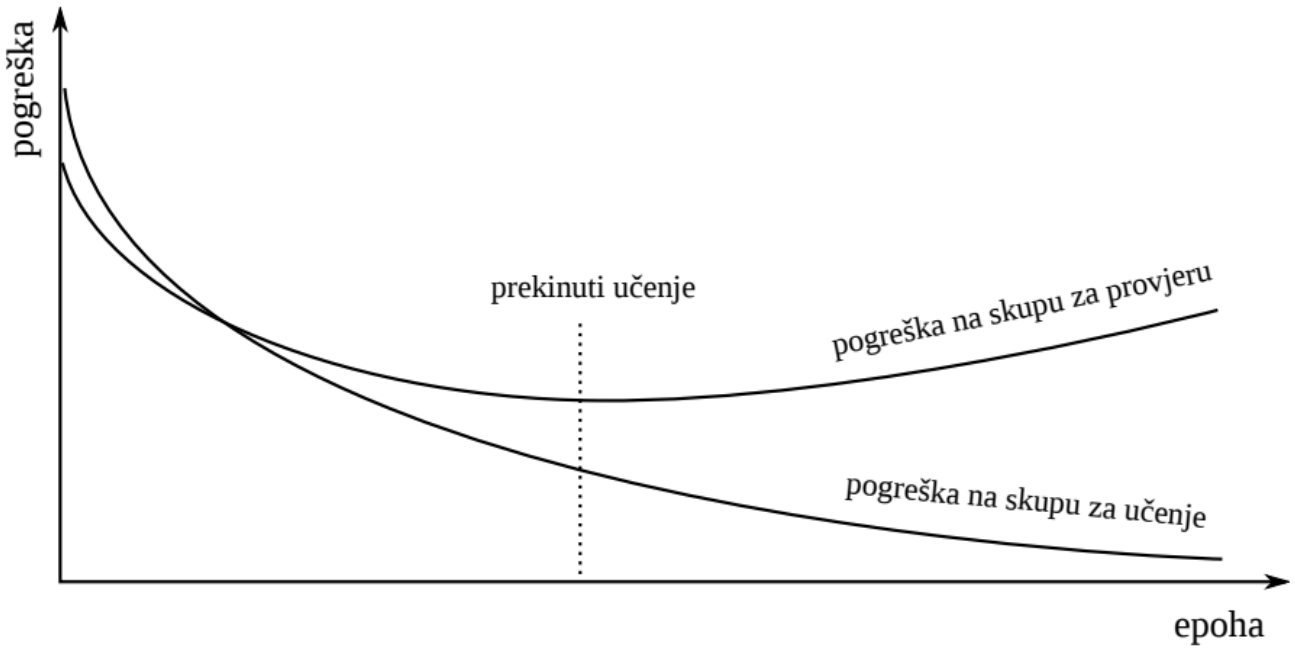

Skup za testiranje

- Ponekad su modeli složeni pa je potrebno odrediti njihovu optimalnu složenost te se zbog toga uvodi **skup za testiranje** (engl. *testing set*) koji također sadrži oko 30% uzoraka skupa za učenje i služi za provjeru točnosti jednom naučenog modela
- Slikovito prikazani skupovi:

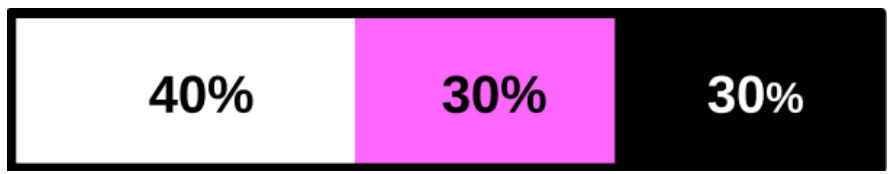

Problemi nadziranog učenja - Regresija

- Regresija (engl. *regression*) je tehnika kojom se pokušava modelirati odnos između određenog broja značajki i kontinuirane ciljne varijable
- Razlikujemo više tipova regresija poput linearne i nelinearne regresije kao i regresije s jednom varijablom i regresije s više varijabli

Problemi nadziranog učenja - Regresija

- Regresija (engl. *regression*) je tehnika kojom se pokušava modelirati odnos između određenog broja značajki i kontinuirane ciljne varijable
- Razlikujemo više tipova regresija poput linearne i nelinearne regresije kao i regresije s jednom varijablom i regresije s više varijabli

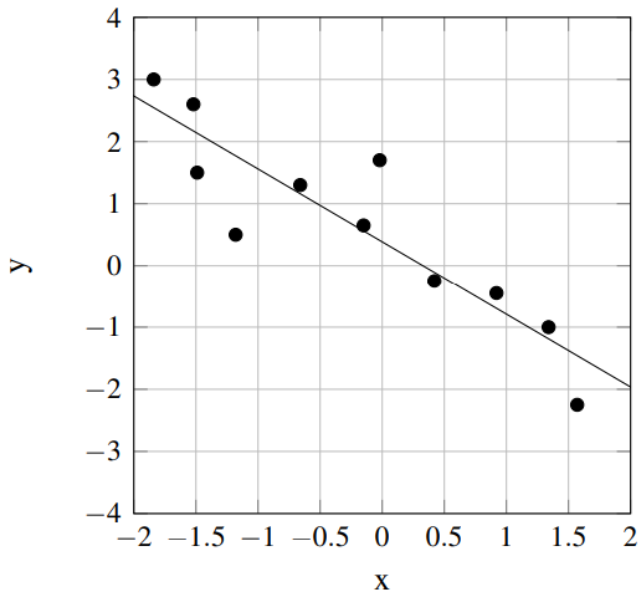

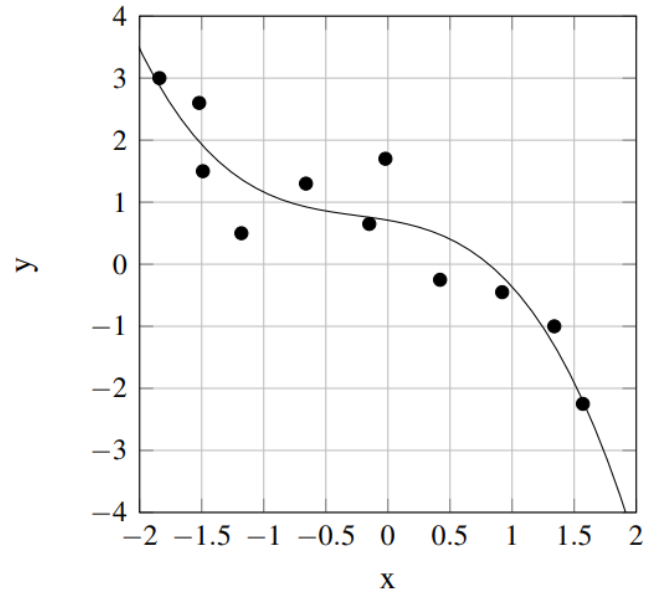

Problemi nadziranog učenja - Klasifikacija

- Klasifikacija (engl. *classification*) je tehnika kojom se određene oznake pokušavaju kategorizirati diskretnim vrijednostima
- Kao i kod regresije, razlikujemo linearnu i nelinearnu klasifikaciju
- Razlikujemo binarnu i višerazrednu klasifikaciju i klasifikaciju više oznaka

Problemi nadziranog učenja - Klasifikacija

- Klasifikacija (engl. *classification*) je tehnika kojom se određene oznake pokušavaju kategorizirati diskretnim vrijednostima
- Kao i kod regresije, razlikujemo linearnu i nelinearnu klasifikaciju
- Razlikujemo binarnu i višerazrednu klasifikaciju i klasifikaciju više oznaka

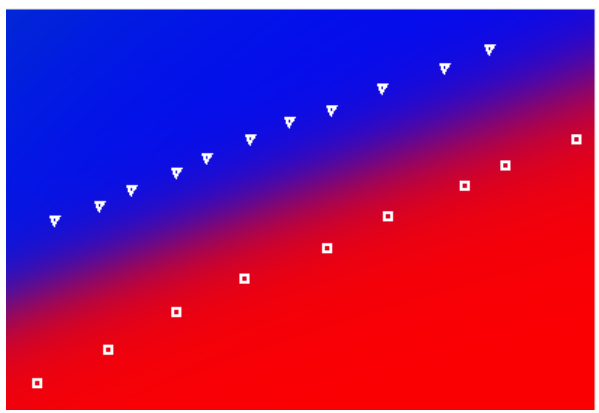

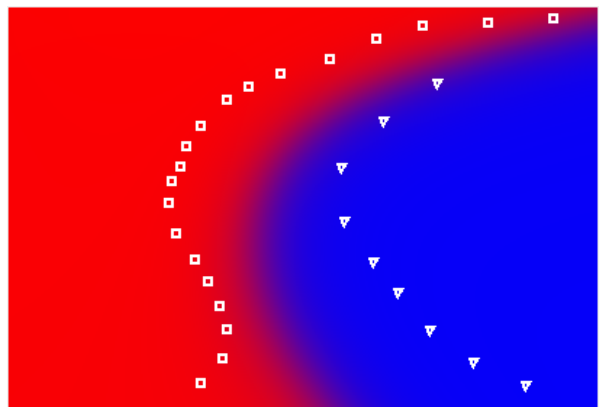

Umjetne neuronske mreže

- Jedan od najkorištenijih algoritama strojnog učenja
- Motivacija pronađena u građi, povezanosti i brzini obrade raznih podražaja ljudskog mozga te mogućnosti učenja iz prijašnjeg iskustva
- Danas je poznato da u ljudskom mozgu postoji oko 10^{11} neurona te 10^{15} međusobnih veza, što znači da je svaki neuron u prosjeku povezan s 10^4 različitih veza
- Primjer konektivističkog pristupa
- Područje koje se bavi proučavanjem umjetnih neuronskih mreža naziva se neuro računarstvo (engl. *neuro-computing*) koje je jedno od grana mekog računarstva (engl. *soft-computing*)

Umjetne neuronske mreže

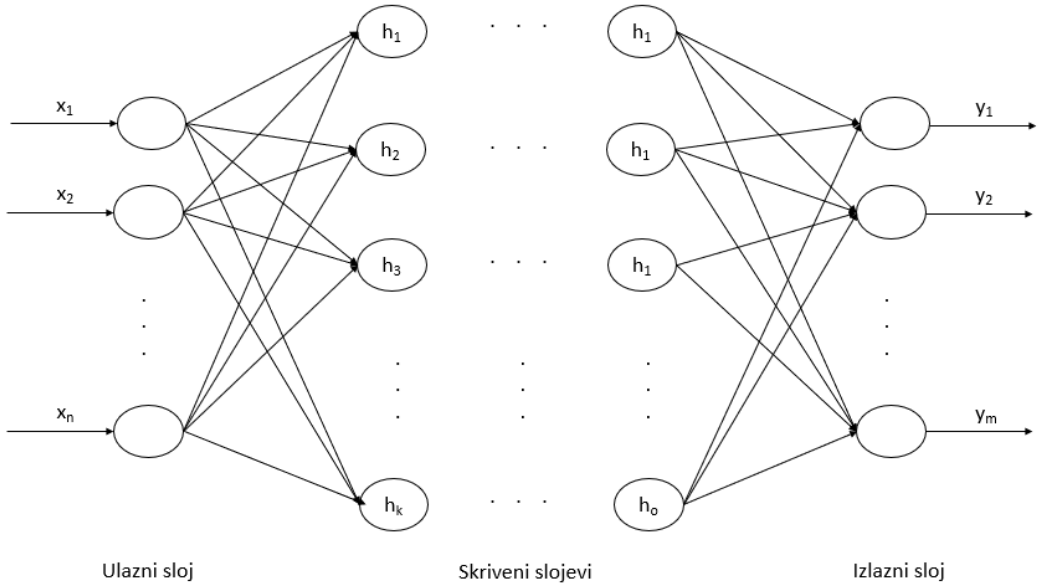

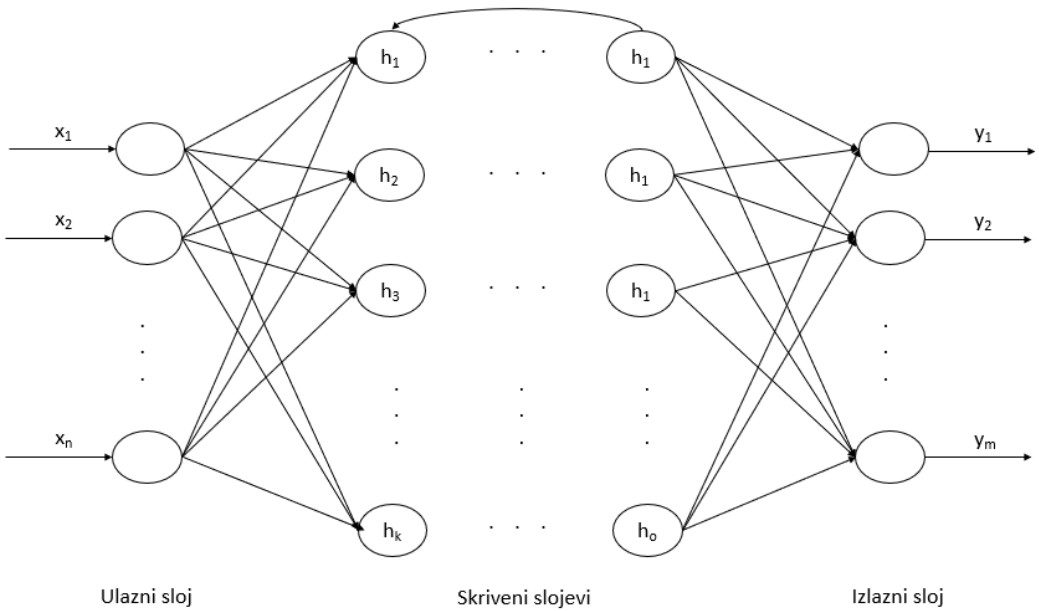

Umjetni neuron

- Motiviran strukturom biološkog neurona:

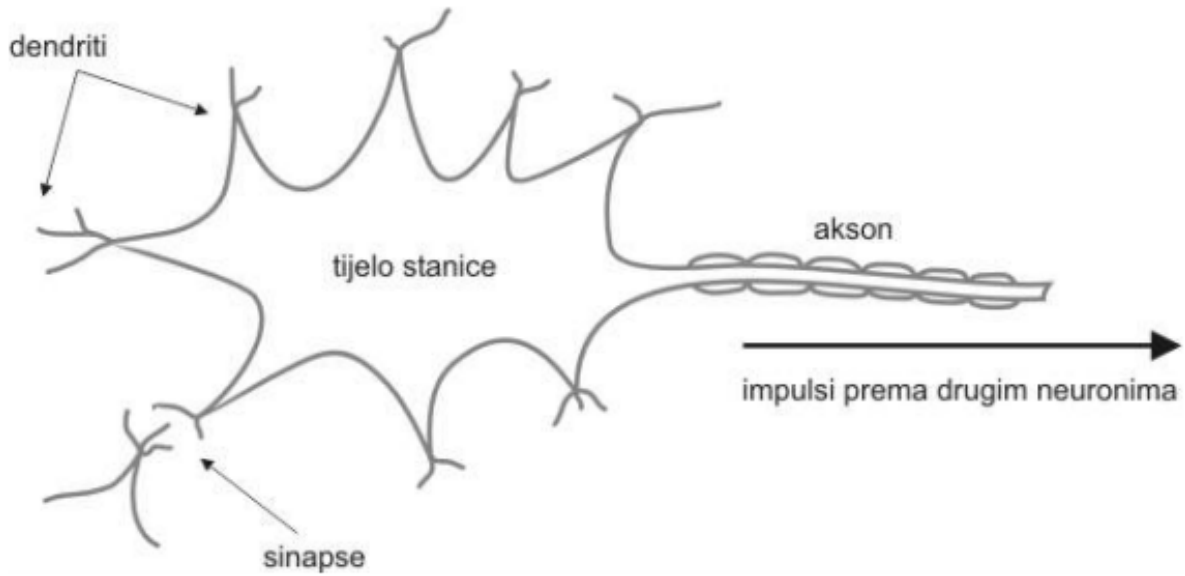

- Definiran 1943. u radu *A Logical Calculus of Ideas Immanent in Nervous Activity* dvojice znanstvenika Warren S. McCulloch i Walter H. Pitts

Umjetni neuron

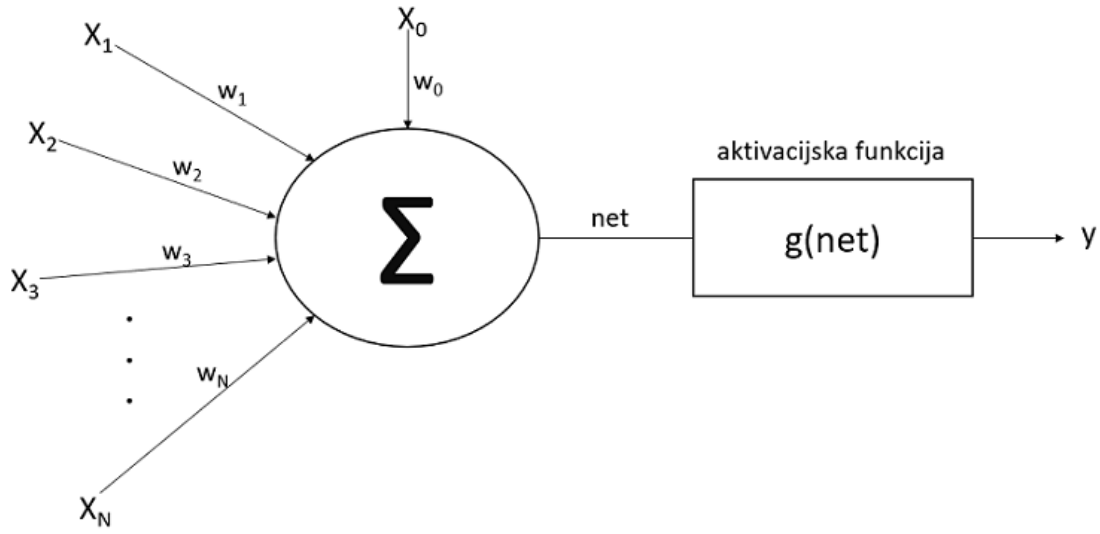

- Sastoji se od $(n+1)$ različitih ulaza **x** i težina **w** te jednog izlaza **y**
- Izlaz se dobije tako što se prvo izračuna **net** vrijednost po formuli:

$$net = \sum_{i=0}^{N} x_i \cdot w_i$$

- Zatim se dobivena **net** vrijednost provuče kroz neku od aktivacijskih funkcija

Aktivacijske funkcije

- U starijoj literaturi nazivane i prijenosnim funkcijama
- Nalaze se tik prije izlaza neurona i određuju hoće li neuron biti aktiviran ili ne, tj. hoće li se "paliti" ili ne
- Razlikujemo binarnu funkciju skoka (engl. *step function*), linearne aktivacijske funkcije poput funkcije identiteta (engl. *identity function*) i nelinearne aktivacijske funkcije poput sigmoidalne (engl. *sigmoid function*), funkcije zglobnice (engl. *Rectified Linear Unit, ReLU*) i dr.
- Svaka od njih različito utječe na izgled **decizijskih granica**, granica između razreda nastalih rezultatom klasifikacije
- Danas se najviše koriste nelinearne aktivacijske funkcije zbog toga što su derivabilne i čije derivacije nisu konstante što uvelike pospješuje učenje mreža
- Funkcija skoka se koristi kod binarne klasifikacije, linearne funkcije kod linearno interpretabilnih problema, a nelinearne se mogu koristiti gotovo uvijek

Aktivacijske funkcije

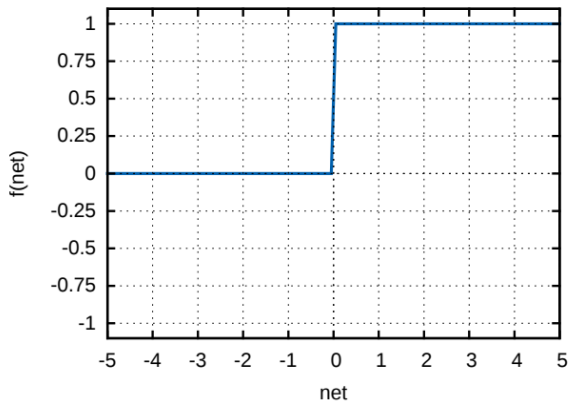

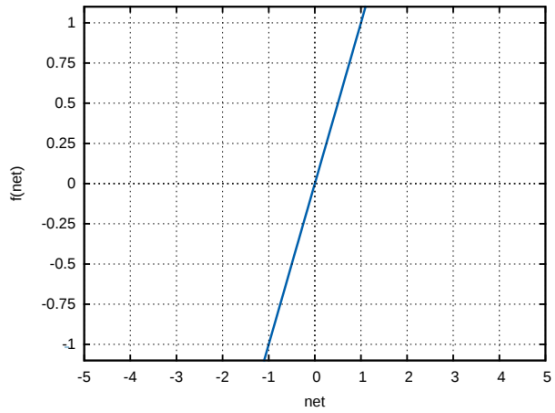

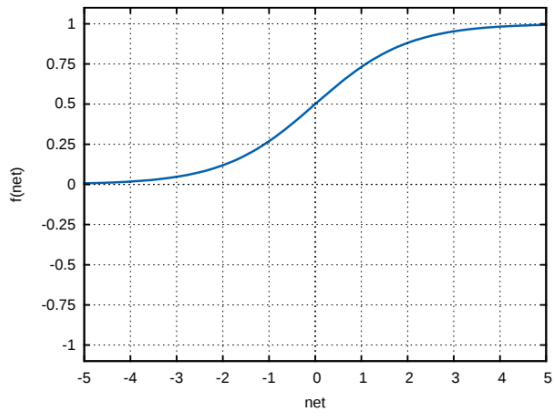

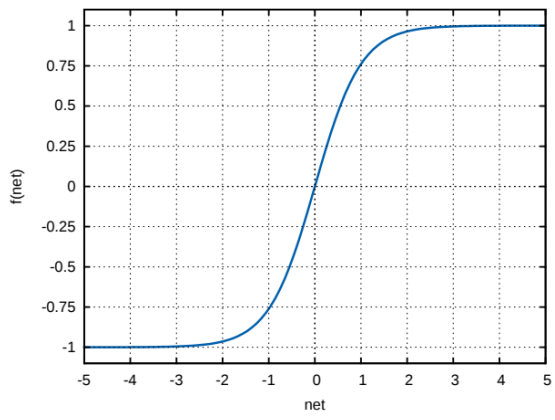

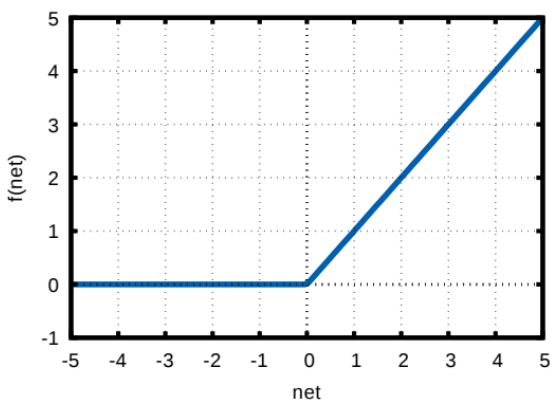

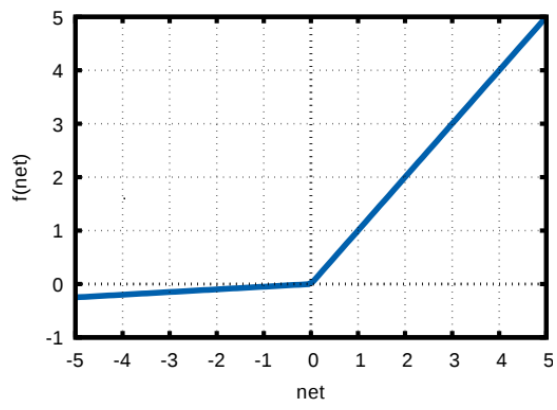

Unaprijedna neuronska mreža

- Unaprijedna višeslojna potpuno povezana umjetna neuronska mreža (engl. *feedforward multilayered fully connected artificial neural network*)
- Operacija **mapiranja** ulaza na određene izlaze
- Često se referira kao **višeslojni perceptron**
- Naziv **perceptron** prvi je upotrijebio 1958. znanstvenik Frank Rosenblatt u svojem radu *The perceptron: a probabilistic model for information storage and organization in the brain*
- Ponukan MCP neuronom i Hebbovim principom učenja razvija prvi algoritam učenja **jednoslojnog perceptrona** koji nije upotrebljiv nad višeslojnim perceptronima zbog čega je dosta kritiziran
- Može sadržavati proizvoljnu arhitekturu, npr. 2x3x2:

Unaprijedna neuronska mreža

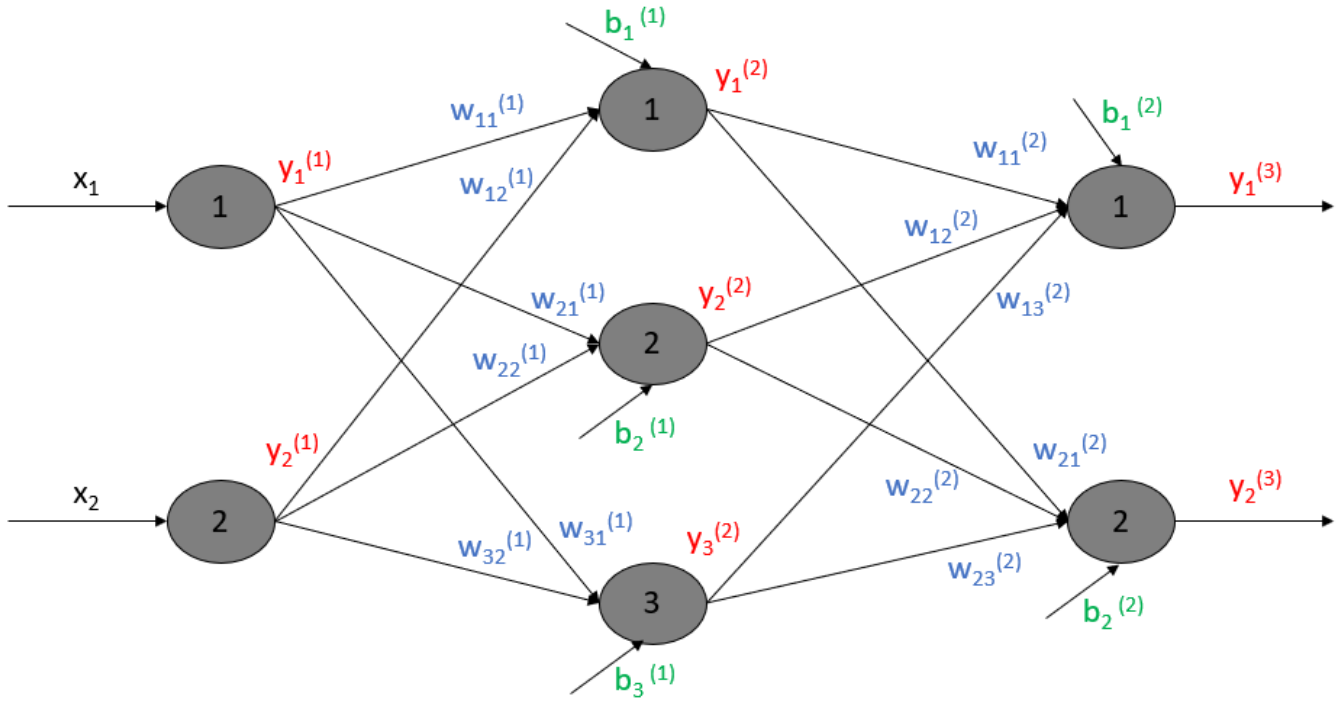

- $w_{jk}^{(l)}$: težina između k-tog neurona (l–1)-vog sloja i j-tog neurona l-tog sloja.
- $b_j^{(l)}$: bias j-tog neurona l-tog sloja.
- $y_j^{(l)}$: izlaz j-tog neurona l-tog sloja.

Unaprijedna neuronska mreža

- Provedba algoritma unaprijedne neuronske mreže je računalno dosta prihvatljivo jer se cijeli postupak može prikazati matričnim računom:

$$\vec{y}^{\,(l+1)} = g(\vec{net}^{(l+1)}) = g(\mathbf{W}^{(l)} \cdot \vec{y}^{\,(l)} + \vec{b}^{\,(l)})$$

- $\mathbf{W}^{(l)}$: matrica svih težina l-tog sloja gdje su retci težine iz svih neurona (l–1)-vog sloja u jedan neuron l-tog sloja.
- $\vec{b}^{\,(l)}$: vektor svih bias vrijednosti l-tog sloja.
- $\vec{net}^{(l)}$: vektor svih net vrijednosti l-tog sloja.
- $\vec{y}^{\,(l)}$: vektor svih izlaza l-tog sloja.
- Važno je napomenuti da neuronska mreže mora raditi s normaliziranim podatcima jer inače neće davati dobre rezultate

Učenje unaprijedne neuronske mreže

- Učenje algoritmom **gradijentni spust** (engl. *gradient descent*):

$$x \leftarrow x - \alpha \cdot \frac{\partial}{\partial x} f(x)$$

- Učenje algoritmom **propagacije pogreške unatrag** (engl. *Backpropagation algorithm*) : računanje parcijalnih derivacija za algoritam gradijentni spust
- 1986. Rumelhart zajedno s dvojicom prijatelja u svojem radu *Parallel Distributed Processing* po prvi put definira termin *Backpropagation* i učenje višeslojnog perceptrona
- Za učenje je potrebno definirati funkciju kazne koju je potrebno minimizirati, odnosno pronaći one vrijednosti težina za koje je iznos funkcije kazne minimalna
- Razmatramo funkciju kazne koja je jednaka polovici srednjeg kvadratnog odstupanja između svakog željenog izlaza mreže i stvarne vrijednosti koju mreža generira na izlazu i to kumulativno za sve raspoložive uzorke:

Učenje unaprijedne neuronske mreže

$$E = \frac{1}{2N} \sum_{s=1}^{N} \sum_{i=1}^{m} (d_{s,i} - y_{s,i}^{(L)})^2$$

- N predstavlja broj uzoraka, m predstavlja broj izlaznih neurona, $d_{s,i}$ predstavlja željeni izlaz i-tog neurona s-tog uzorka, a $y_{s,i}^{(L)}$ predstavlja stvarni izlaz i-tog neurona s-tog uzorka
- Potrebno je ažurirati težine sljedećim pravilom:

$$w_{jk}^{(l)} \leftarrow w_{jk}^{(l)} - \alpha \cdot \frac{\partial E}{\partial w_{jk}^{(l)}}$$

- Na prvu izgleda kao da je to moguće izvesti klasičnim računom traženja parcijalnih derivacija, no mreže su često jako kompleksnih arhitektura i takav postupak bi resursno i vremenski bio prezahtjevan, stoga tu nastupa algoritam propagacije pogreške unatrag

Učenje unaprijedne neuronske mreže

1. Ciklički prolazi kroz svih N uzoraka za učenje, jedan po jedan.
2. Ponavljaj dok nije zadovoljen uvjet zaustavljanja.
3. Za svaki uzorak iz skupa uzoraka za učenje čini:
   1. Postavi uzorak na ulaz neuronske mreže i izračunaj izlaze za sve neurone primjenom formule unaprijedne neuronske mreže.
   2. Izračunaj pogrešku svakog od neurona izlaznog sloja po formuli:
   $$\delta_{s,j}^{(L)} = g'(net_{s,j}^{(L)}) \cdot (d_{s,j} - y_{s,j}^{(L)}).$$
   3. Vraćaj se sloj po sloj i izračunaj pogreške svakog neurona po formuli:
   $$\delta_{s,j}^{(l)} = g'(net_{s,j}^{(l)}) \cdot \sum_{i=1}^{m} \delta_{s,i}^{(l+1)} \cdot w_{i,j}^{(l)}.$$
   4. Ažuriraj težine po formuli:
   $$w_{jk}^{(l)} \leftarrow w_{jk}^{(l)} + \eta \cdot \sum_{s=1}^{N} \delta_{s,j}^{(l+1)} \cdot y_{s,k}^{(l)}.$$
   5. Ažuriraj biase po formuli:
   $$b_{j}^{(l)} \leftarrow b_{j}^{(l)} + \eta \cdot \sum_{s=1}^{N} \delta_{s,j}^{(l+1)}.$$

Rezultati

- U sklopu rada implementirano je grafičko korisničko sučelje kroz koje se interaktivno unose točke u 2D koordinatnom sustavu te se iste predaju neuronskoj mreži na učenje
- Točke su normalizirane tako da su se stvarne koordinate podijelile sa stvarnom širinom, odnosno visinom prozora kako bi se dobili brojevi iz intervala $[0, 1]$
- Težine i biasi su inicijalizirane pomoću Xavier inicijalizacije i to tipom normalne razdiobe gdje očekivanje iznosi 0, a standardna devijacija iznosi $\sqrt{\frac{1}{n^{(l-1)}}}$. Nazivnik predstavlja broj neurona u prijašnjem sloju.
- Moguće je izabrati 3 različita razreda pri unosu točaka gdje svaki razred predstavlja svoju boju iz RGB raspona
- Interno je svaki razred kodiran sa svojim kodom pa tako točka pripada crvenom razredu ako mreža na izlazu generira $[1, 0, 0]$, zelenom razredu ako generira $[0, 1, 0]$ i plavom razredu ako generira $[0, 0, 1]$

Rezultati

- Mreža naravno neće davati tako okrugle brojeve pa ih je potrebno zaokružiti sljedećim pravilom: ako je izlaz manji ili jednak 0.5, onda ga postavi na 0, inače na 1. Tako će npr. izlaz $[0.6, 0.3, 0.1]$ biti transformiran u $[1, 0, 0]$ te će se uzorak klasificirati kao da pripada crvenom razredu
- Boja svakog uzorka grafičkog sučelja se određuje tako da se uzmu onoliki postoci svake od komponenata RGB koji se generiraju na izlazima. Tako će npr. izlaz $[0.6, 0.3, 0.1]$ poprimiti 0.6 crvene boje, 0.3 zelene boje i 0.1 plave boje.
- Prije učenja je moguće izabrati tri različite aktivacijske funkcije koje djeluju samo na skrivenim slojevima, dok se na izlaznom sloju nalazi funkcija **softmax** koja na temelju svih izlaza generira postotke pripadnosti svakom od razreda gdje vrijedi da je suma svih postotaka potpuna i iznosi 100%
- U nastavku su dani primjeri linearne i nelinearne klasifikacije kao i primjer prenaučenosti

Rezultati

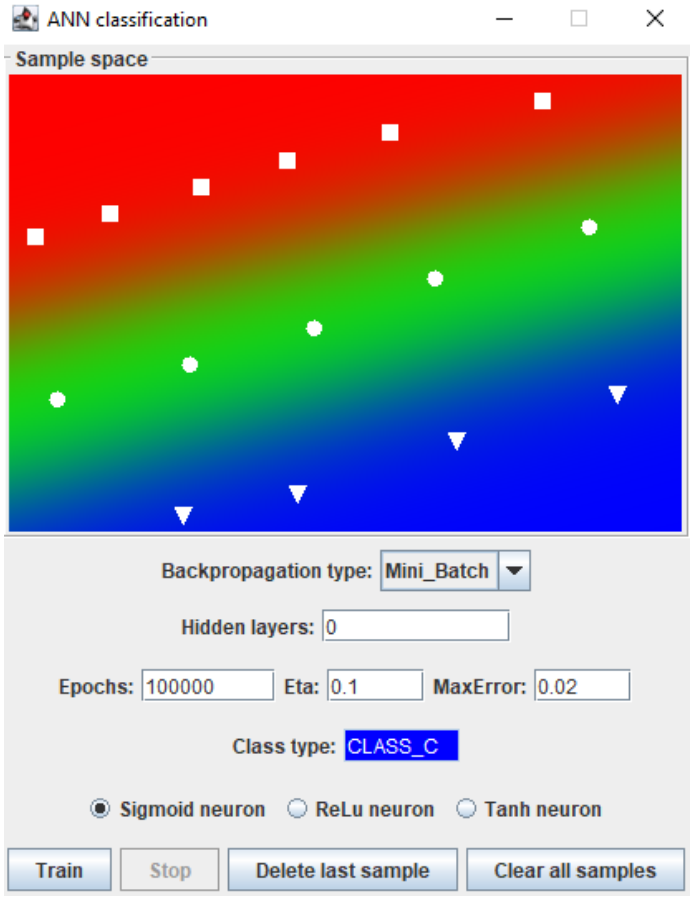
ANN classification
Sample space
Backpropagation type: Mini_Batch
Hidden layers: 0
Epochs: 100000 Eta: 0.1 MaxError: 0.02
Class type: CLASS_C
Sigmoid neuron ReLu neuron Tanh neuron
Train Stop Delete last sample Clear all samples

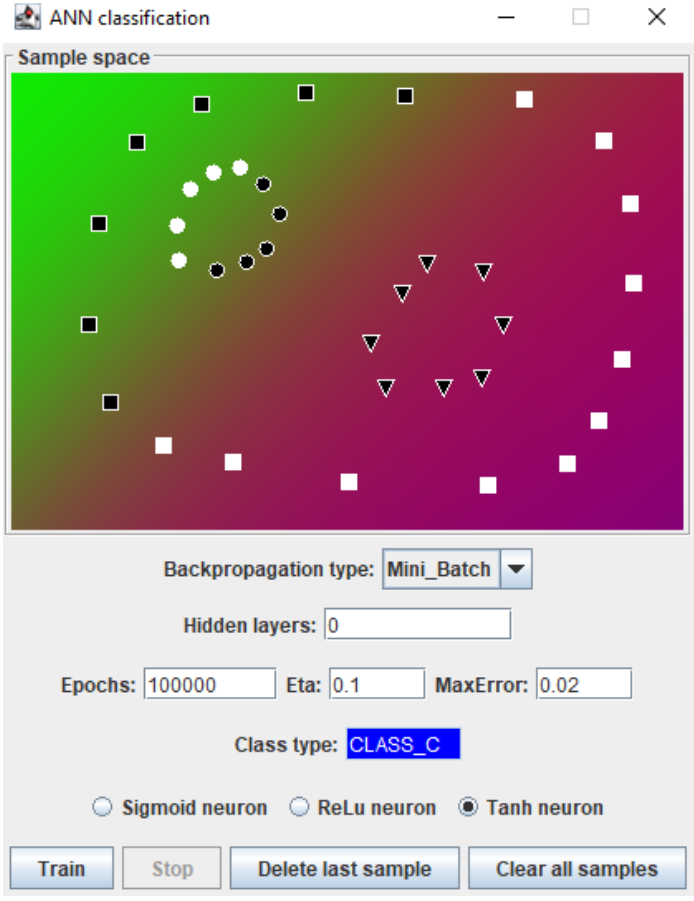
ANN classification
Sample space
Backpropagation type: Mini_Batch
Hidden layers: 0
Epochs: 100000 Eta: 0.1 MaxError: 0.02
Class type: CLASS_C
Sigmoid neuron ReLu neuron Tanh neuron
Train Stop Delete last sample Clear all samples

Rezultati

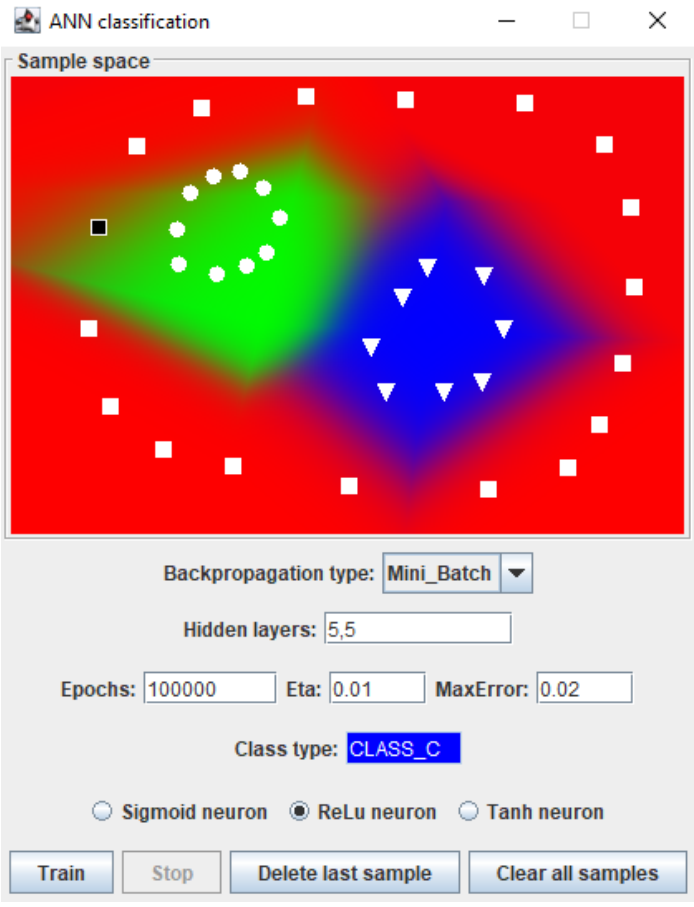
ANN classification
Sample space
Backpropagation type: Mini_Batch
Hidden layers: 5,5
Epochs: 100000 Eta: 0.01 MaxError: 0.02
Class type: CLASS_C
Sigmoid neuron ReLu neuron Tanh neuron
Train Stop Delete last sample Clear all samples

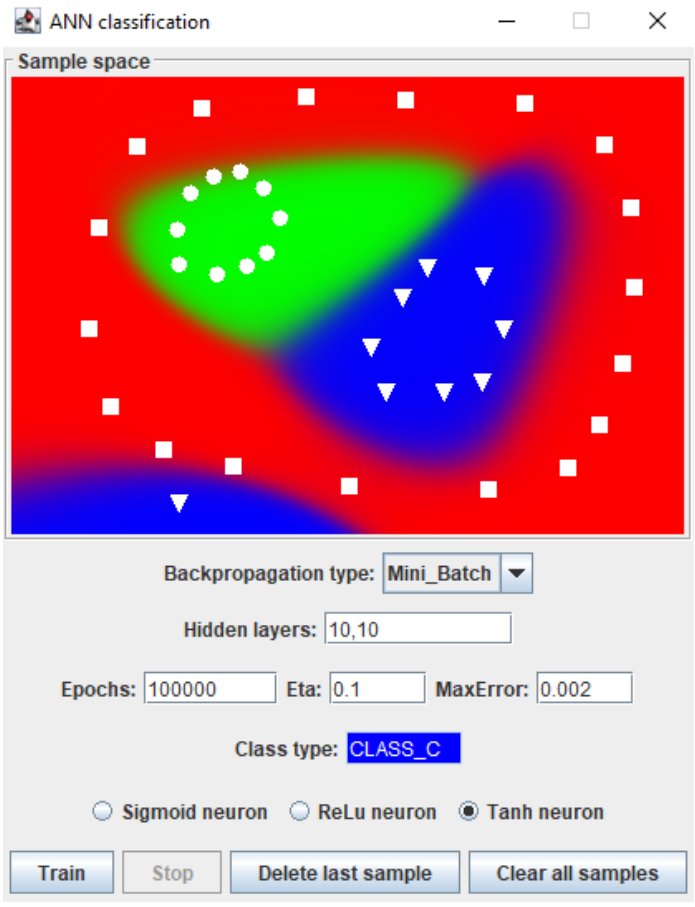
ANN classification
Sample space
Backpropagation type: Mini_Batch
Hidden layers: 10,10
Epochs: 100000 Eta: 0.1 MaxError: 0.002
Class type: CLASS_C
Sigmoid neuron ReLu neuron Tanh neuron
Train Stop Delete last sample Clear all samples

Zaključak

- Za rješavanje određenih problema treba jako dobro poznavati teoriju koja se krije iza algoritma umjetnih neuronskih mreža
- Pametna inicijalizacija težina je jako bitna za postizanje dobrih rezultata unaprijednom neuronskom mrežom kao i odabir arhitekture te aktivacijskih funkcija

Zaključak

- Za rješavanje određenih problema treba jako dobro poznavati teoriju koja se krije iza algoritma umjetnih neuronskih mreža
- Pametna inicijalizacija težina je jako bitna za postizanje dobrih rezultata unaprijednom neuronskom mrežom kao i odabir arhitekture te aktivacijskih funkcija

Mogući nastavci na ovaj rad

- Proučiti inačice algoritma propagacije pogreške unatrag te ih znati primijeniti na probleme koje rješavamo
- Upoznati se s dubokim neuronskim mrežama i algoritmima dubokog učenja