

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 000

Klasifikacija uporabom umjetnih neuronskih mreža

Darijo Brčina

Zagreb, svibanj 2020.

*Umjesto ove stranice umetnite izvornik Vašeg rada.
Da bi ste uklonili ovu stranicu obrišite naredbu \izvornik.*

SADRŽAJ

1. Uvod	1
2. Pregled područja	2
2.1. Umjetna inteligencija	3
2.1.1. Simboličko učenje	3
2.1.2. Strojno učenje	3
3. Nadzirano učenje	6
3.1. Učenje modela	6
3.2. Problemi nadziranog učenja	8
3.2.1. Regresija	9
3.2.2. Klasifikacija	11
3.3. Algoritmi	13
4. Umjetne neuronske mreže	14
4.1. Motivacija	14
4.2. Biološki neuron	14
4.3. Umjetni neuron	15
4.3.1. Povijesni pregled	15
4.3.2. Perceptron	17
4.4. Unaprijedna neuronska mreža	17
4.5. Učenje unaprijedne neuronske mreže	17
4.5.1. Algoritam propagacije pogreške unatrag	17
5. Rezultati	18
6. Zaključak	19
Literatura	20

1. Uvod

Uvod rada. Nakon uvoda dolaze poglavlja u kojima se obrađuje tema.

2. Pregled područja

Pitate li se ikada što je to inteligencija te čemu nam služi. To pitanje postavljeno je još za vrijeme začetka filozofije kao znanosti kada su se tadašnji filozofi pitali kako i na koji način je ljudsko razmišljanje, učenje i pamćenje ostvareno. Ni dan danas ne postoji jednoznačan odgovor na to pitanje jer ljudski mozak i dalje predstavlja jednu veliku nepoznanicu koja vjerojatno nikada ili ne tako skoro neće biti razriješena. No znanost je podosta napredovala i shodno tomu se razvila želja da se ljudska inteligencija pokuša pretočiti u nekakvu vrstu inteligencije strojeva.

Početak ovakvog razmišljanja datira od 50-tih godina dvadesetog stoljeća kada Alan Turing u članku *Computing Machinery and Intelligence* časopisa *Mind* postavlja pitanje: Mogu li strojevi misliti? (engl. *Can machines think?*) na koje pokušava odgovoriti kroz tzv. igru imitacije (engl. *imitation game*). Sudionici igre su tri igrača: igrač A, igrač B i igrač C gdje su igrači A i B ispitanici a igrač C ispitivač. Cilj igrača C je utvrditi spol ispitanika postavljanjem pitanja, cilj igrača B je pomoći ispitivaču C a cilj igrača A je navesti ispitivača C na pogrešnu identifikaciju. Što će se dogoditi ako stroj uzme mjesto igrača A? Ako broj pogrešaka igrača C bude gotovo jednak u oba slučaja, onda je stroj inteligentan. (Turing, 1950). Ovakav princip se često naziva turingov test (engl. *Turing test*).

Nedugo nakon turingovog eksperimenta, 1956. se održava konferencija u Dartmouthu (Dartmouth workshop, 2020) na inicijativu John McCarthy-a, tadašnjeg mladog profesora matematike na fakultetu u Dartmouthu, koji okuplja oko sebe nekolicinu znanstvenika i prijatelja kako bi pokušali koncepte ljudske inteligencije preslikati u inteligenciju strojeva. Cilj je pokazati kako strojevi koriste jezik, kako zaključuju i stvaraju apstraktne koncepte i kako vremenom postaju sve prilagodljiviji na predložene probleme baš kao i ljudi. Inicijalna ideja je bila da se neki od navedenih problema može dokazati uz manju skupinu dobrih znanstvenika i kroz period od jednog ljeta (McCarthy et al. 1955). To naravno nije bilo moguće. Time se formalno uvodi pojam *umjetna inteligencija*.

2.1. Umjetna inteligencija

Kao što je anticipirano ranije, umjetna inteligencija (engl. *artificial intelligence*) je laički rečeno inteligencija strojeva a znanost koja se jednim dijelom bavi proučavanjem umjetne inteligencije jest računarska znanost (engl. *computer science*).

Primjena umjetne inteligencije danas je izrazito rasprostranjena kroz gotovo svaku industriju. Pronalazimo ju u medicini, automobilske industriji, robotici, pa i u sportskoj i industriji igara. Jedan od poznatijih događaja koji prikazuje primjenu umjetne inteligencije dogodio se 2016. kada je računalo naziva *AlphaGo* u igri *Go* uspijelo pobijediti svjetskog prvaka Lee Sedolu rezultatom 4:1 te time ostvario velik uspjeh u svijetu umjetne inteligencije kao i pažnju javnosti (Moyer, 2016).

Umjetnu inteligenciju je dakako potrebno trenirati i učiti pa je tako učenje podijeljeno na dvije veće cjeline:

1. simboličko učenje te
2. strojno učenje.

2.1.1. Simboličko učenje

Simbolička umjetna inteligencija (engl. *symbolic artificial intelligence*) je izraz koji definira skup istraživačkih metoda koje se temelje na ljudima lako čitljivim simbolima (engl. *human-readable symbol*) koji modeliraju probleme i logiku. Jedan od najboljih primjera jesu *ekspertni sustavi* koji se temelje na skupu pravila. Pravila su modelirana na sličan način kao i Ako-Onda rečenica (engl. *If-Then statement*) koja je u ljudskoj komunikaciji svakodnevno u upotrebi. Također, razne vrste logika poput propozicijska (engl. *Propositional logic*), često referirana kao Boolova algebra, logika prvog reda (engl. *First order logic*), poznatija kao predikatna logika (engl. *Predicate logic*), neizrazita logika (engl. *Fuzzy logic*) pripadaju upravo simboličkoj umjetnoj inteligenciji. Ovakav način učenja bio je popularan početkom 1950. sve do kraja 1980 (Symbolic artificial intelligence, 2020).

2.1.2. Strojno učenje

Strojno učenje (engl. *machine learning, ML*) predstavlja niz metoda i algoritama koji sustavima pružaju stjecanje novog znanja kroz modeliranje obrazaca koje onda kasnije mogu iskoristiti za predviđanje novih podataka ili sličnih (Čupić, 2020). Glavna ideja

je da sustavi uče iz iskustva, empirijski, bez da se programska implementacija mijenja što znatno olakšava manipulaciju istih.


Danas postoji nezgrapno puno podataka koje je moguće i koje je potrebno iskoristiti za učenje pa je cilj konstruirati sustave koji mogu iskoristiti baš te podatke za neka korisna ponašanja poput predviđanja i raspoznavanja raznih uzoraka (Čupić, 2020). Podatci se svrstavaju u dvije grupe: *numerički* i *kategorički* podatci. Numerički podatci su svi oni podatci nad kojima je moguće izvršiti aritmetičke operacije. Npr. unos dnevnih kalorija, broj slobodnih bacanja na košarkaškoj utakmici, isplata plaća i sl. Kategorički podatci se dodatno dijele u dvije podgrupe: nominalni i ordinalni podatci. Nominalni podatci su imenovani podatci koji nisu numerički, tj. podatci nad kojima nisu definirane aritmetičke operacije. Npr. podatci o spolu jedinke, osjećaju raspoloženja poput "tužan" ili "veseo" i sl. Ordinalni podatci također nemaju definiranu aritmetiku, no imaju definiran prirodan poredak i mogu se uspoređivati. Npr. mišljenje jedne osobe može biti "jako zadovoljan" dok druge "zadovoljan" što možemo usporediti i konstruirati prirodan poredak.

Strojno učenje dijelimo na četiri područja:

1. nadzirano učenje,
2. nenadzirano učenje,
3. polu-nadzirano učenje te
4. podržano učenje.

Nadzirano učenje je tema ovog rada pa će biti obrađeno detaljnije u narednom poglavlju.

Nenadzirano učenje (engl. *unsupervised learning*) je vrsta učenja u kojem skup podataka predstavljaju samo ulazni podatci bez znanja o tome kako bi isti trebali biti tabelirani. Zbog ovakvog pristupa, učenje je i dobilo ime nenadzirano učenje, tj. učenje bez prisustva učitelja (engl. *supervisor*). Najpoznatiji postupak nenadzirano učenja je postupak grupiranja (engl. *clustering*). Cilj grupiranja je na temelju danih podataka pokušati pronaći sve podatke koji imaju slična svojstva te ih zatim grupirati u odvojene razrede. Npr. neka skup ulaznih podataka sustava bude mješavina slika ljudi i slika automobila. Kao konačni rezultat, moraju se stvoriti dva razreda: razred ljudi te razred automobila. Na slici 2.1 prikazan je primjer grupiranja.




Slika 2.1: Primjer grupiranja¹

Uz grupiranje poznati postupci su i postupci smanjenja dimenzionalnosti (engl. *dimensionality reduction*), postupci otkrivanja stržećih ili novih vrijednosti (engl. *outlier detection*, *novelty detection*) i drugi.

Polu-nadzirano učenje (engl. *semi-supervised learning*), kao što samo ime nalaže, je učenje u kojem se isprepliću koncepti nadzirano učenje sa konceptima nenadziranim učenjem. Ono pokazuje dosta veće uspjehe nego navedeni, izvedba je izrazito zahtjevnija (Semi-supervised learning, 2020).

Podržano učenje (engl. *reinforcement learning*, *RL*) je vrsta učenja koja se potpuno razlikuje od svih do sada navedenih jer ono ne očekuje nikakve tabelirane ulazne ili izlazne podatke već je glavna ideja optimizacija ponašanja računalnih agenata. Razmatra se interakcija agenta sa okolinom (engl. *environment*) kroz niz akcija za koje isti može biti nagrađen ili kažnjen ovisno o ishodu akcije. Željeni cilj agenta je maksimizirati mogući dobitak nagrade (Reinforcement learning, 2020). Na slici 2.2 prikazan je model podržanog učenja.



Slika 2.2: Model podržanog učenja²

¹Preuzeto sa <https://www.geeksforgeeks.org/clustering-in-machine-learning/>.

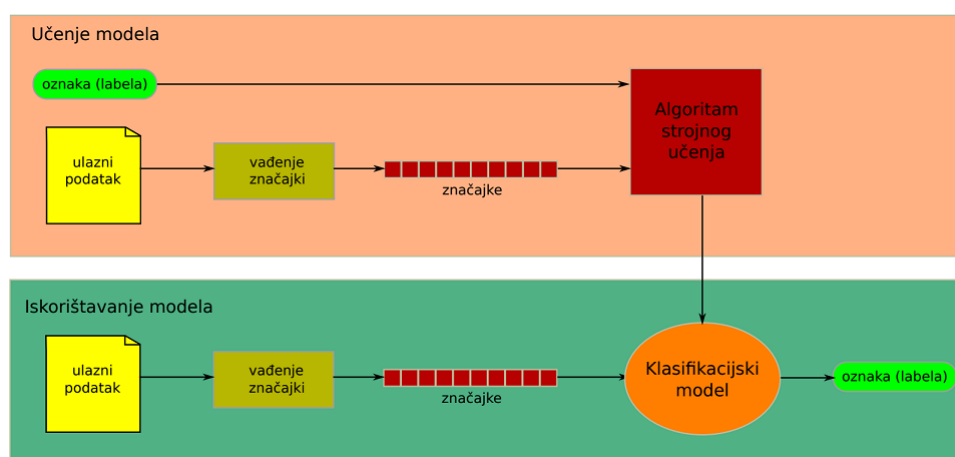
²Preuzeto sa <https://www.kdnuggets.com/2018/03/5-things-reinforcement-learning.html/>.

3. Nadzirano učenje

Nadzirano učenje (engl. *supervised learning*) je vrsta učenja čiji je cilj sve podatke koji dođu na ulaz sustava preslikati u izlaz koji točno odgovara predanim ulazima. Dakle, prije samog učenja poznati su ulazi, koji se često modeliraju vektorima, te izlazi, koji su pridruženi tim ulazima i predstavljaju jedan podatak, stoga se tijekom učenja u svakom trenutku zna željeni izlaz te se za krive rezultate daje određena povratna informacija (engl. *feedback*) o tome koliko sustav griješi. Upravo zbog navedenog koncepta je učenje i dobilo ime nadzirano učenje jer se proces učenja izvršava uz prisustvo učitelja (engl. *supervisor*). Razlikujemo dvije faze strojnog modela prikazane na slici 3.1:

1. faza učenja modela te
2. faza iskorištavanja modela.

3.1. Učenje modela



Slika 3.1: Model strojnog učenja¹


¹Preuzeto iz literature (Čupić, 2020).

Tijekom faze učenja, modelu se predaje skup ulaznih podataka za učenje (engl. *training set*). Svaki podatak skupa možemo notirati kao $(\mathbf{x}, y)_i$ što predstavlja i -ti primjer iz skupa za učenje gdje \mathbf{x} predstavlja vektor ulaznih podataka, a y vrijednost pridružena ulaznom vektoru, odnosno oznaku (engl. *label*). Ulazni podatak često može biti kompleksne naravi što znači da ga je potrebno "razbiti" u manje cjeline. Takav postupak se naziva vađenje značajki (engl. *feature extraction*). Rezultat navedenog je kolekcija značajki koja se zatim predaje određenom algoritmu strojnog učenja. Npr. ulazni podaci mogu biti razne gume poput gume automobila, gume bicikla, gume traktora i sl. a značajka bi onda mogla biti volumen gume, oblik gume, boja gume i sl. Algoritam strojnog učenja će na temelju predanih značajki pokušati optimizirati parametre odabranog modela kako bi se isti mogao koristiti u sljedećoj fazi.

Faza iskorištavanja modela predstavlja fazu u kojoj se treba utvrditi radi li naučeni model sa podacima nad kojima nije učio, tj. je li razvio sposobnost generalizacije (engl. *generalization*). Ako model dodijeli točnu oznaku za većinu ulaznih podataka, onda možemo reći da je razvio svojstvo generalizacije. No što ako u velikoj mjeri ne uspije točno povezati izlaze sa ulazima? Ako dođe to takve pojave, kažemo da je model pretreniran (engl. *overfitting*). Do navedene pojave dolazi kada model nauči previše nad skupom podataka za učenje, tj. podatke za učenje nauči savršeno raspoznavati dok za nove podatke ne uspijeva dati željene rezultate. Postoji nekoliko načina kako se može utjecati da model razvije svojstvo generalizacije a spomenut ćemo samo jedan od njih, *unakrsna provjera*.

Unakrsna provjera (engl. *cross-validation*) je postupak koji se koristi tijekom faze učenja modela. Ideja je da se dio podataka iz skupa za učenje razdijeli u novi skup, skup za provjeru (engl. *validation set*). Skup za provjeru često sadrži od 20% do 30% svih podataka iz skupa za učenje (Čupić, 2020). Tijekom faze učenja modela, model će i dalje učiti samo nad skupom za učenje dok ćemo mu povremeno dati i podatke iz skupa za provjeru čisto da se vidi koliko griješi nad njima. Važno je napomenuti da model nad podacima iz skupa za provjeru neće učiti, tj. neće optimizirati parametre već će bit prisiljen da nauči generalizirati. Postavlja se pitanje do kada će faza učenja modela onda trajati i odgovor je vrlo jasan. Trajat će do trenutka kada pogreška nad skupom za provjeru počinje rasti. Dijagram na slici 3.2 prikazuje kako model uči kroz epohe².

²Epohe je ništa drugo nego jedna iteracija učenja, ali u strojnom učenju se često koristi izraz epoha pa ćemo se držati konvencije.



Slika 3.2: Kretanje pogrešaka pri učenju strojnog modela³

Također postoji mogućnost da neki od parametara modela utječu na njegovu složenost. Shodno tomu se uvodi još jedan skup, skup za testiranje (engl. *testing set*). Ideja je sljedeća: skup podataka razdijelimo u sva tri do sada navedena skupa i normalno provedemo fazu učenja modela uz malu promjenu. Umjesto da se zadovoljimo samo jednim naučenim modelom, pokušavamo pronaći onaj model koji će najbolje minimizirati pogrešku nad skupom za testiranje (Čupić, 2020).

3.2. Problemi nadziranog učenja

Zadatak nadziranog učenja je sljedeći: pretpostavimo da imamo skup za učenje koji se sastoji od N različitih parova ulaza i izlaza;

$$(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), (\mathbf{x}_3, y_3), \dots, (\mathbf{x}_N, y_N)$$

gdje \mathbf{x}_i predstavlja i -ti vektor ulaznih podataka dok y_i i -ti željeni izlaz koji je generiran nekom nepoznatom funkcijom $y = f(x)$.

Potrebno je pronaći takvu funkciju h koja će najbolje aproksimirati funkciju f .

Funkcija h naziva se hipoteza (engl. *hypothesis*) i pripada nekom skupu svih hipoteza \mathbf{H} koje donekle aproksimiraju zadanu funkciju f , neke bolje, neke lošije. U ovom trenutku uključujemo skup za testiranje u proces učenja jer je potrebno pronaći onu hipotezu za koju će aproksimacija biti najbolja, tj. ukupna pogreška generirana tijekom učenja modela bit će minimalna. Time će se osigurati da model poprimi svojstvo generalizacije. Često se pokazuje da je funkcija f stohastička (engl. *stochastic*), što

³Preuzeto iz literature (Čupić, 2016).

znači da ne ovisi uvijek samo o varijabli x pa se mora koristiti i uvjetovana vjerojatnost $P(Y|x)$ tijekom faze učenja modela (Russell i Norvig, 2009)⁴.

Kao što je rečeno ranije, y_i predstavlja i -ti željeni izlaz za i -ti ulaz te može poprimiti vrijednost broja ili vrijednost iz nekog konačnog skupa podataka. Ako je slučaj da je izlaz broj, radi se o problemu koji se naziva *regresija*, a ako je slučaj da je izlaz vrijednost iz nekog konačnog skupa podataka, onda se radi o problemu koji se naziva *klasifikacija*.

3.2.1. Regresija

Regresija (engl. *regression*) je tehnika, tj. algoritam nadziranog učenja koji se koristi kada je potrebno predvidjeti određeni iznos neke funkcije u odnosu na određene parametre. Dakle, dane podatke potrebno je aproksimirati nekom proizvoljnom funkcijom h koja je često polinomijalna. Postoje različite vrste regresije pa spomenimo neke od njih.

Prije svega, postoji regresija s jednom varijablom (engl. *regression with one variable*) i regresija sa više varijabli (engl. *multivariate regression*). Razlika je očita, no pokažimo to na kratkom primjeru. Recimo da želimo modelirati cijene obiteljskih kuća u okolini Zagreba. Za to su nam potrebni neki parametri na temelju kojih ćemo moći vršiti predikcije kao npr. broj kvadratnih metara (m^2), broj spavaćih soba, blizina vrtića i škola, povezanost sa javnim prijevozom i sl. U slučaju regresije s jednom varijablom, za modeliranje bi uzeli samo jedan od navedenih parametara, dok bi u slučaju regresije sa više varijabli uzeli sve ili dio navedenih. Dakle, očigledno je da je regresija s jednom varijablom konkretan slučaj regresije sa više varijabli.


Linearna regresija (engl. *linear regression*) je tip regresije koji koristi linearnu krivulju (pravac), tj. polinom prvog stupnja kao aproksimacijsku krivulju.

Polinomijalna regresija (engl. *polynom regression*) je tip regresije koji koristi polinom reda r kao aproksimacijsku krivulju.


Na slikama 3.3 i 3.4 su prikazani navedeni tipovi regresija.

Dakle, regresija je metoda koja se koristi za predviđanje numeričkih ishoda.

⁴Iz poglavlja 18.2 Supervised learning.



Slika 3.3: Primjer linearne regresije⁵



Slika 3.4: Primjer polinomijalne regresije sa kubnim polinomom⁶

⁵Preuzeto iz literature (Čupić, 2020).

⁶Preuzeto iz literature (Čupić, 2020).

3.2.2. Klasifikacija

Klasifikacija (engl. *classification*) je tehnika, tj. algoritam nadziranog učenja koji se koristi kada je određen ulazni podatak potrebno smjestiti odnosno klasificirati kao pripadnika određenog razreda. Izlazi tako organiziranog modela često poprimaju diskretne vrijednosti za razliku od regresije i takav model onda nazivamo klasifikator (engl. *classifier*). Razlikujemo nekoliko različitih tipova klasifikatora:

1. binarni klasifikator,
2. višerazredni klasifikator te
3. klasifikator više oznaka.

Binarni klasifikator (engl. *binary classifier*) je tip klasifikatora koji zna odrediti pripada li ulazni podatak jednom od ukupno dva moguća razreda. Npr. sustav kao ulaze prima slike na kojima se nalazi ili mačka ili pas. Jednom naučeni klasifikator bi na temelju predane slike morao moći odrediti što se nalazi na slici, mačka ili pas. Naravno uz uvjet da se preda slika mačke ili psa.

Višerazredni klasifikator (engl. *multi-class classifier*) je tip klasifikatora koji zna odrediti pripada li ulazni podatak jednom od barem tri moguća razreda. Dakle, mora postojati minimalno tri različita razreda kako bi se klasifikator nazivao višerazrednim. U ovom radu ćemo se više fokusirati upravo na navedenom klasifikator koji će naučiti raspoznati tri moguća razreda, no o tome nešto kasnije.

Klasifikator više oznaka (engl. *multi-label classifier*) je tip klasifikatora koji predstavlja generalizaciju višerazrednog klasifikatora. Pogledajmo sljedeći primjer klasifikacije filmova za bolje razumijevanje. Pretpostavimo da film može imati sljedeće oznake: (12+), (16+) i (18+) gdje svaka oznaka predstavlja minimalan broj godina kojih gledaoc filma mora imati. Određivanje oznake za pojedini film je rezultat korištenja višerazrednog klasifikatora jer je potrebno odrediti pripada li film samo jednom od navedene tri oznake. No što ako film poželimo klasificirati pomoću žanrova? Tada nam višerazredni klasifikator neće puno pomoći jer jedan film može imati više oznaka kao npr. "drama" i "komedija" i sl. Tada ćemo koristiti klasifikator više oznaka.


Klasifikaciju, kao i regresiju, možemo podijeliti na *linearnu klasifikaciju* i *nelinearnu klasifikaciju*, odnosno polinomijalnu.

Linearna klasifikacija (engl. *linear classification*) je tip klasifikacije u kojoj se granica između razreda aproksimira pomoću linearna krivulje, tj. pravca.


Nelinearna klasifikacija (engl. *non-linear classification*) je tip klasifikacije u kojoj se granica između razreda aproksimira pomoću nelinearne krivulje koja je često polinomijalna.

Ono što je zajedničko u oba slučaja je postojanje granice između razreda koja se u literaturi naziva *decizijska granica* (Čupić, 2016). O oblicima decizijskih granica će biti riječ kasnije.

Na slikama 3.5 i 3.6 su prikazani primjeri klasifikacija.



Slika 3.5: Primjer linearne klasifikacije⁷



Slika 3.6: Primjer nelinearne klasifikacije⁸

⁷Rezultat programske implementacije.

⁸Rezultat programske implementacije.

3.3. Algoritmi

U području nadziranog učenja postoji veliki broj algoritama koji uvelike pridonose boljem učenju. Neki od poznatijih su:

- Stroj za podršku vektorima (engl. *support-vector machine, SVM*),
- Stabla odluke (engl. *decision trees*),
- Naivni Bayesov klasifikator (engl. *naive Bayes classifier*),
- Slučajne šume (engl. *random forests*),
- Algoritam k-najbližih susjeda (engl. *k-nearest neighbors algorithm*),
- Umjetna neuronska mreža (engl. *artificial neural network*) i mnogi drugi.

Vidimo da postoji jako velika paleta algoritama od kojih su neki složeniji od drugih, neki daju bolje rezultate od drugih, no niti jedan od algoritama nije u stanju uvijek dati najbolje rezultate za proizvoljan problem nadziranog učenja (Supervised learning, 2020). Zbog navedenog vrijedi tzv. *No free lunch* teorem koji nalaže da je za probleme koji zahtijevaju mnogo računalnih resursa poput pretraživanja prostora stanja i optimizacije parametara složenost u prosjeku jednaka za sve metode (No free lunch theorem, 2020).

U sljedećem poglavlju ćemo se detaljnije baviti algoritmom *umjetna neuronska mreža*. Pogledat ćemo kako je nastao koncept umjetnog neurona, strukturu umjetnog neurona, arhitekturu unaprijedne neuronske mreže te algoritam kojim unaprijedna neuronska mreža uči.

4. Umjetne neuronske mreže

U drugom poglavlju (*Pregled područja*) dotaknuli smo se razlika između simboličke umjetne inteligencije i strojnog učenja i rekli smo kako simbolička umjetna inteligencija koristi simbolički pristup, tj. sve iskaze pokušava predočiti u mnoštvo pravila pomoću ljudima čitljivim simbolima, dok se strojno učenje bavi raznim algoritmima pomoću kojih se računalni sustav uči. U ovom poglavlju bavit ćemo se algoritmom strojnog učenja koji koristi tzv. konektivistički pristup.


4.1. Motivacija

Ideja za konektivizmom (engl. *connectivism*) potaknuta je na temelju strukture ljudskog mozga te zbog izrazite brzine kojom mozak obrađuje podražaje. Danas je poznato da u ljudskom mozgu postoji oko 10^{11} neurona te 10^{15} međusobnih veza što znači da je svaki neuron u prosjeku povezan sa 10^4 različitih veza (Čupić et al., 2013). To upravo dokazuje da mozak predstavlja jedan kompleksan i paralelan sustav zbog čega je konektivizam dobio ime te čemu algoritam umjetne neuronske mreže teži. Također, koncept ljudskog mozga nije uzet samo radi svoje izrazite brzine prilikom obrade podražaja, već i zbog činjenice da ga se može učiti na temelju velikog broja podataka koji su često ispunjeni raznim šumovima, što je realna situacija, te ga time potaknuti da razvije svojstvo generalizacije. Područje koje se bavi proučavanjem umjetnih neuronskih mreža naziva se neuro-računarstvo (engl. *neuro-computing*) koje je jedno od grana mekog računarstva (engl. *soft-computing*).

4.2. Biološki neuron

Neuroni (engl. *neurons*) su glavne stanice mozga i živčanog sustava. Zadaća im je da primaju podražaje iz okoline, da prenose određene akcije od mozga prema našim mišićima i da vode računa o pretvaranju električnog potencijala između pojedinih neurona u svim koracima procesa vođenja. Neuron je izgrađen od posebne strukture koja

se sastoji od: *tijela stanice* (ili češće *soma*), *dendrita*, *aksona*, i *sinapse*. Struktura biološkog neurona prikazana je na slici 4.1.



Slika 4.1: Biološki neuron¹

Dendriti (engl. *dendrites*) su ulazni dijelovi neurona, tj. strukture koje prihvaćaju impulse od drugih neurona preko veza koje se nazivaju sinapse. Suma svih ulaznih impulsa, tj. potencijala određuje hoće li dotični neuron biti aktiviran ili ne.

Aksoni (engl. *axons*) su izlazni dijelovi neurona, tj. strukture u kojima se generira određeni električni potencijal koji se dalje prosljeđuje sljedećem neuronu preko sinoptičkih veza.

Sinapse (engl. *synapses*) su, kao što je rečeno ranije, veze između dendrita jednog neurona i aksona drugog neurona (Woodruff, 2019).

4.3. Umjetni neuron

4.3.1. Povijesni pregled

MCP neuron


1943. dva znanstvenika, Warren McCulloch i Walter Pitts, u svojem radu *A Logical Calculus of Ideas Immanent in Nervous Activity* definiraju strukturu prvog umjetnog neurona koji se u literaturi često naziva kao MCP neuron. Na slici 4.2 prikazana je struktura MCP neurona. Dendriti su predstavljeni ulazima označenih slovima E od

¹Preuzeto iz literature (Čupić, 2016).

riječi ekscitacijski² (engl. *excitatory*) te **I** od riječi inhibicijski³ (engl. *inhibitory*), tijelo stanice je predstavljeno slovom **T** od riječi prag (engl. *threshold*) dok je akson predstavljen izlazom koji je označen slovom **Y** bez posebnog značenja.

Ekscitacijski ulazi uzrokuju da neuron postane aktivan, tj. da se neuron "pali" (engl. *fire*), dok inhibicijski ulazi uzrokuju da neuron postane neaktivan, tj. da se neuron "ne pali". Točnije, ako postoji barem jedan inhibicijski ulaz koji je aktivan, tada će neuron sigurno biti neaktivan neovisno o svim ostalim ulazima. Također, ako niti jedan od inhibicijskih ulaza nije aktivan, onda će neuron postati aktivan samo u slučaju kada je suma svih ekscitacijskih ulaza veća ili jednaka pragu, T (McCulloch i Pitts, 1943). Matematički rečeno (Picton, 2000):

$$Y = \begin{cases} 1 & \text{if } \sum_{i=1}^n I_i = 0 \text{ and } \sum_{j=1}^m E_j \geq T \\ 0 & \text{otherwise.} \end{cases} \quad (4.1)$$



Slika 4.2: MCP neuron⁴

MCP neuron mogao je modelirati osnovne Booleove logičke operacije kao što su operacija *i* (engl. *and*), operacija *ili* (engl. *or*) i operacija negacije (engl. *not*) pa se može reći da neuron predstavlja logička vrata (engl. *logic gate*) što je često korištena struktura prilikom konstrukcija uređaja poput računala koji mogu rješavati kompleksne logičke izraze. Shodno tomu se razvilo vjerovanje da se ljudski mozak sastoji upravo

²ekscitacija - uzbuđenje ili aktivirano stanje zbog određenog podražaja (ekscitacija. Hrvatska enciklopedija, mrežno izdanje. Leksikografski zavod Miroslav Krleža, 2020. Pristupljeno 13. 5. 2020. <<http://www.enciklopedija.hr/Natuknica.aspx?ID=17398>>).

³inhibicija - kočenje prijenosa živčanih impulsa (inhibicija. Hrvatska enciklopedija, mrežno izdanje. Leksikografski zavod Miroslav Krleža, 2020. Pristupljeno 13. 5. 2020. <<http://www.enciklopedija.hr/Natuknica.aspx?ID=27450>>).

⁴Preuzeto iz literature (Picton, 2000) iz poglavlje 1.4.2 Biologically inspired neural networks.

od mnoštva logičkih vrata, no nisu uzimali u obzir činjenicu da takva konstrukcija ne može biti učena te da nema svojstvo generalizacije (Picton, 2000).

Postoji još jedna bitna stavka oko strukture MCP neurona koja je prešutno korištena, a to su vrijednosti koje poprimaju ulazi i izlazi. Vrijednosti koje mogu poprimiti su iz skupa $\{0, 1\}$ i niti jedne druge, dok vrijednost praga može biti decimalan broj. To se implicitno moglo zaključiti iz spomenutih primjena na Boolove operacije te iz formule (4.1).

ADALINE

4.3.2. Perceptron

4.4. Unaprijedna neuronska mreža

4.5. Učenje unaprijedne neuronske mreže

4.5.1. Algoritam propagacije pogreške unatrag

5. Rezultati

6. Zaključak

Zaključak.

LITERATURA

Dartmouth workshop. Dartmouth workshop — Wikipedia, the free encyclopedia, ožujak 2020. URL https://en.wikipedia.org/wiki/Dartmouth_workshop. [Aktivno; pristupljeno 10-Maj-2020].

Linear regression. Linear regression — Wikipedia, the free encyclopedia, maj 2020. URL https://en.wikipedia.org/wiki/Linear_regression. [Aktivno; pristupljeno 12-Maj-2020].

Warren S. McCulloch i Walter H. Pitts. A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, 5:115–133, 1943.

Christopher Moyer. How Google’s AlphaGo Beat a Go World Champion, ožujak 2016.

No free lunch theorem. No free lunch theorem — Wikipedia, the free encyclopedia, maj 2020. URL https://en.wikipedia.org/wiki/No_free_lunch_theorem. [Aktivno; pristupljeno 12-Maj-2020].

Phil Picton. *Neural Networks*. PALGRAVE, u drugom izdanju, 2000.

Reinforcement learning. Reinforcement learning — Wikipedia, the free encyclopedia, maj 2020. URL https://en.wikipedia.org/wiki/Reinforcement_learning. [Aktivno; pristupljeno 11-Maj-2020].

S. Russell i P. Norvig. *Artificial Intelligence - A Modern Approach*. Prentice Hall, u trećem izdanju, prosinac 2009.

Semi-supervised learning. Semi-supervised learning — Wikipedia, the free encyclopedia, travanj 2020. URL https://en.wikipedia.org/wiki/Semi-supervised_learning. [Aktivno; pristupljeno 11-Maj-2020].

Supervised learning. Supervised learning — Wikipedia, the free encyclopedia, maj 2020. URL https://en.wikipedia.org/wiki/Supervised_learning. [Aktivno; pristupljeno 12-Maj-2020].

Symbolic artificial intelligence. Symbolic artificial intelligence — Wikipedia, the free encyclopedia, travanj 2020. URL https://en.wikipedia.org/wiki/Symbolic_artificial_intelligence. [Aktivno; pristupljeno 10-Maj-2020].

Alan Turing. Computing Machinery and Intelligence. *Mind*, stranice 433 – 460, listopad 1950.

Unsupervised learning. Unsupervised learning — Wikipedia, the free encyclopedia, travanj 2020. URL https://en.wikipedia.org/wiki/Unsupervised_learning. [Aktivno; pristupljeno 11-Maj-2020].

Alan Woodruff. What is a neuron?, kolovoz 2019. URL <https://qbi.uq.edu.au/brain/brain-anatomy/what-neuron>. [Aktivno; pristupljeno 13-Maj-2020].

M. Čupić, B. Dalbelo Bašić, i M. Golub. *Neizrazito, evolucijsko i neuroračunarstvo*, kolovoz 2013. URL <http://java.zemris.fer.hr/nastava/nenr/knjiga-0.1.2013-08-12.pdf>. [Aktivno; pristupljeno 13-Maj-2020].

Marko Čupić. *Umjetne neuronske mreže*, svibanj 2016. URL <http://java.zemris.fer.hr/nastava/ui/ann/ann-20180604.pdf>. [Aktivno; pristupljeno 11-Maj-2020].

Marko Čupić. *Uvod u strojno učenje*, travanj 2020. URL <http://java.zemris.fer.hr/nastava/ui/ml/ml-20200410.pdf>. [Aktivno; pristupljeno 10-Maj-2020].

Klasifikacija uporabom umjetnih neuronskih mreža

Sažetak

Sažetak na hrvatskom jeziku.

Ključne riječi: Ključne riječi, odvojene zarezima.

Classification Based on Artificial Neural Networks

Abstract

Abstract.

Keywords: Keywords.